

# Traffic Sign Classifier

《自動駕駛實務》專案二

數據一 RE6121011 徐仁瓏

## 壹、介紹

隨著自動駕駛技術的發展，交通標誌識別成為關鍵研究領域。準確識別交通標誌能提高自動駕駛車輛的導航能力和安全性。本專案旨在設計並訓練一個基於 AlexNet 的深度學習模型，用於識別德國交通標誌。透過數據預處理、超參數調整，我們提升了模型的準確性和泛化能力。最終，我們在實際數據集上測試模型，並分析其預測結果和性能，以期為交通標誌識別技術的研究和自動駕駛技術的進一步發展提供貢獻。

## 貳、資料前處理

在交通標誌分類專案中，資料的前處理是確保模型成功訓練的關鍵一步。透過精心的資料前處理，我們能夠為模型提供清晰、一致的數據，從而提高其預測能力。

我們的數據集源自 German Traffic Sign Dataset，其中包含各種交通標誌的圖片及其對應的標籤。這個數據集結構明確，包含了 34799 張圖像及其標籤的訓練集、4410 張圖像及其標籤的驗證集和 12630 張圖像及其標籤的測試集，這樣的資料切分比例讓我們能夠充分訓練和評估我們的模型。其中，所有的圖像均為 32×32 像素的 RGB 圖像，且數據集中總共有 43 種類別的交通標誌，我們的目標是希望能盡可能地將 43 種交通標誌都分類正確。




圖 1 數據集中 43 種不同的交通標誌類別

從圖 1 中，我們繪製出了數據集中共 43 種不同的交通標誌類別，這是我們希望可以正確分類出來的所有類別，每種交通標誌都有其名稱，關於其對應的名稱可以在 signnames.csv 檔案中得到。

接著，我們分別將訓練集、驗證集和測試集中 43 種交通標誌的個數用直方圖的繪製出來，如圖 2 所示。透過圖 2 我們可以觀察到三張直方圖的分配看似相近，並無太大明顯的差異，這樣的相似性可以確保我們在進行模型訓練和模型評估時，可以得到較好的結果，因為我們蒐集到的樣本（即訓練集和驗證集）和我們想要推論的結果（即測試集）之間沒有過多的偏誤，因此在效能評估上也比較具有可信度。




圖 2 訓練集、驗證集和測試集中 43 種交通標誌個數的直方圖

最後，我們將所有的圖像進行標準化處理，以提高模型訓練的效果，最終將處理後的資料保存為 pickle 文件，以便後續的模型訓練和測試使用。

## 參、模型建構

我們的模型參考 AlexNet 的架構作設計，AlexNet 是一種經典的卷積神經網絡架構，以其在 ImageNet 圖像分類挑戰中的優異表現而聞名。以下是我們建構的 AlexNet 神經網絡架構：

- **卷積層 1**：輸入圖像大小為  $32 \times 32 \times 3$ ，使用  $5 \times 5$  大小的卷積核生成  $28 \times 28 \times 9$  的特徵圖，然後透過 ReLU 激活函數進行非線性轉換，最後進行最大池化操作，將特徵圖尺寸減半為  $14 \times 14 \times 9$ 。
- **卷積層 2**：對第一層卷積特徵圖進行  $3 \times 3$  大小的卷積操作，生成  $12 \times 12 \times 32$  的特徵圖，同樣使用 ReLU 激活函數進行非線性轉換，再次進行最大池化操作，將特徵圖尺寸減半為  $6 \times 6 \times 32$ 。
- **卷積層 3**：對第二層卷積特徵圖進行  $3 \times 3$  大小的卷積操作，並採用 SAME padding 以保持特徵圖大小不變，生成  $6 \times 6 \times 48$  的特徵圖，同樣使用 ReLU 激活函數進行非線性轉換。
- **卷積層 4**：對第三層卷積特徵圖進行  $3 \times 3$  大小的卷積操作，並採用 SAME padding 以保持特徵圖大小不變，生成  $6 \times 6 \times 64$  的特徵圖，同樣使用 ReLU 激活函數進行非線性轉換。
- **卷積層 5**：對第四層卷積特徵圖進行  $3 \times 3$  大小的卷積操作，並採用 SAME padding 以保持特徵圖大小不變，生成  $6 \times 6 \times 96$  的特徵圖，同樣使用 ReLU 激活函數進行非線性轉換，然後進行最大池化操作，將特徵圖尺寸減半為  $3 \times 3 \times 96$ ，最後將特徵圖攤平，以利後續全連階層使用。
- **全連接層 1**：輸入為 864 維的展平特徵向量，輸出為 400 維，同時應用 ReLU 激活函數。為了減少過擬合，在激活函數之後應用 Dropout 技術，以概率 0.5 丟棄部分神經元。
- **全連接層 2**：輸入為 400 維，輸出為 160 維，同時應用 ReLU 激活函數。為了減少過擬合，再次在激活函數之後應用 Dropout 技術，以概率 0.5 丟棄部分神經元。
- **輸出層**：輸入為 160 維，輸出為 43 維，代表 43 個不同的交通標誌類別。

這就是我們構建的 AlexNet 神經網絡架構，它為我們的交通標誌分類任務提供了堅實的基礎。

## 肆、模型訓練

在模型訓練階段，我們精心設置了一系列超參數，以確保模型在訓練過程中獲得最佳的性能。這些超參數包括學習率（Learning Rate）、訓練次數（Epochs）和批次大小（Batch Size）。學習率設置為  $5 \times 10^{-4}$ ，控制了模型參數的更新速率。訓練次數設置為 30，代表整個訓練數據集被遍歷的次數。批次大小設置為 128，每次訓練模型時所使用的樣本數量。通過適當調整這些超參數，我們能夠控制模型的收斂速度和準確性，從而更好地擬合訓練數據。

在優化器和損失函數的選擇方面，我們採用了 Adam 優化器和交叉熵損失函數。Adam 優化器具有良好的收斂性能，能夠有效地調整學習率，從而加快模型的收斂速度。而交叉熵損失函數是多類分類任務中的常用損失函數，能夠準確地衡量模型預測與實際標籤之間的差異，有助於指導模型的訓練過程。

在訓練過程中，我們將訓練數據集進行了隨機打亂，並將其分為大小為 128 的批次進行訓練。通過這種方式，我們能夠更好地利用數據集的信息，減少模型對於訓練數據的記憶效應，從而提高模型的泛化能力。在每個訓練次數結束後，我們還使用驗證數據集來評估模型的準確性，從而及時發現模型的問題並進行調整。

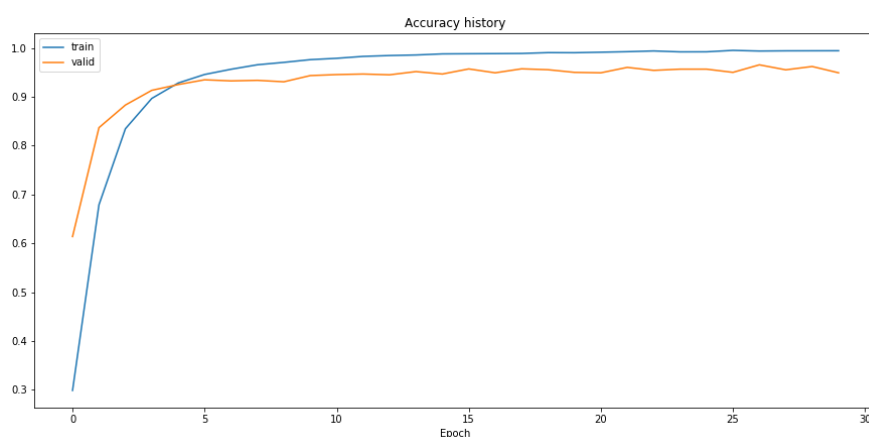


圖 3 訓練集和測試集中隨訓練次數變化的準確度曲線

在圖 3 中，我們可以發現訓練集的準確度幾乎已經到達 100% 了，而驗證集的準確度也已趨於平緩，代表可以不用繼續訓練下去了。在這次的訓練中，我們在驗證集中得到最高的準確度為 96%。

## 伍、模型評估和預測

訓練完模型後，我們把這個最好的模型拿去測試集作預測，最終得到高達 94.6% 的準確度。我們把此次訓練的模型分別在訓練集、驗證集和測試集上作評估，如圖 4 所示，發現不管在哪個資料集上，我們的模型都能達到相當高的準確度，這意味著我們能夠非常正確地分類出 43 種不同的交通號誌。




圖 4 訓練集、驗證集和測試集的準確度比較

評估完模型後，我們隨機從測試集中抽取 10 張未見過的交通標誌圖像來作預測，每張圖像都是來自不同的標誌種類，看看預測結果是否真的如上述所示可以分辨得這麼好，這些標誌種類分別來自標籤 0、1、3、5、8、23、26、30、32、42。我們將這 10 張圖像秀出來，如圖 5 所示。



圖 5 測試集中隨機抽取 10 張未見過的交通標誌圖

將這 10 張圖像丟入模型後，預測結果竟然全部預測正確，我們的模型測試準確度達到了 100%，顯示了模型對於新圖像的預測能力。最後，我們進一步地打印出了每個圖片的前五個最可能的類別和相應的概率。通過這種方式，我們可

以清晰地看到模型對於每個圖片的預測情況，並且對於預測的結果進行了解釋，從而更好地理解模型的性能和優缺點，預測結果如圖 6 所示。

從圖 6 中，我們可以發現 10 張圖像中不只皆預測正確，而且每個預測結果都是顯示 100% 預測到正確的標籤上，由此可見，模型不僅準確度高，也具有相當的穩健性，表示並不容易不小心就預測成其他類別的標籤，預測結果十分良好。




圖 6 抽取 10 張圖像中前五個最可能的類別和相應的概率

## 陸、結論與展望

本研究通過使用 AlexNet 架構成功地訓練了一個模型來識別德國交通標誌。我們對數據進行了正規化的預處理，並在模型中引入了多層卷積層和全連接層，使用 Dropout 技術來減少過擬合。經過訓練，我們的模型在驗證集上達到了令人滿意的準確度，並且在測試集上也展示了良好的預測能力，證明了我們的模型具有較強的泛化能力。

儘管本研究取得了較好的成果，但仍有一些改進的空間和未來的研究方向，在數據增強方面，未來可以引入數據增強技術，如隨機旋轉、平移、縮放等，以增加數據的多樣性，進一步提高模型的泛化能力。此外，可以嘗試使用更深層次的網絡結構，如 ResNet 或 DenseNet，來進一步提升模型的性能。在超參數調整方面，可以進一步調整學習率、批次大小等超參數，進行更多實驗以尋找最佳參數組合。最後我們也能嘗試對模型作實時應用，即將模型應用於實時交通標誌識別系統中，測試其在實際場景中的性能，並進行相應的優化和改進。通過這些改進和探索，我們有信心能夠進一步提升模型的性能，並推動交通標誌識別技術在智能交通領域的應用。